DATAMINING · B3

Projet de fin de module

Neuf sujets · groupes de 4 à 6 · soutenance orale

Ce qu'on vous demande

Vous êtes une équipe de consultants. Une entreprise vous ouvre ses fichiers et vous pose neuf questions — les siennes, telles qu'elles se posent en comité de direction. Personne ne vous dira quelle méthode employer, ni quelles colonnes regarder.

Votre travail : répondre à ces neuf questions avec des résultats chiffrés, puis **dire à l'entreprise ce qu'elle doit faire**. Un graphique n'est pas une réponse. Une réponse, c'est un chiffre, une décision et ce qu'elle rapporte.

Comment ça se passe

- Vous formez un **groupe de 4 à 6 personnes** et vous choisissez un sujet parmi les neuf.
- Vous inscrivez dans le fichier **Groupes_projets** : le sujet choisi, le nom et le prénom de chaque membre, et le lien de votre dépôt dans la colonne **RENDU**.
- Les sujets sont dans le dossier **Sujets**, les fichiers de données dans le dossier **Donnees**, un sous-dossier par sujet.
- Deux sujets identiques dans la promo, c'est possible — mais deux rendus identiques, non.

Le dépôt Git

Vous ne rendez rien d'autre que le lien d'un **dépôt Git public**. Il contient le code, le README et le PDF de vos slides.

- **Chaque membre du groupe commite depuis son compte.** Un dépôt où une seule personne a poussé du code est un dépôt où une seule personne a travaillé, et la note le dira.
- **Des commits réguliers, pas un dépôt livré en une fois la veille.** On doit voir le travail avancer : des messages lisibles, des étapes.
- Le **README** raconte votre démarche : ce que vous avez compris de chaque question, la méthode retenue, pourquoi celle-là, et ce que vous en concluez. Le reste va en commentaire dans le code.

> **La règle qui fait la différence**
>
> Pour chaque question, vous devez **justifier le choix de la méthode** : pourquoi celle-là plutôt qu'une autre, et ce que vous avez vérifié avant de faire confiance au résultat. Une bonne réponse sans justification vaut la moitié des points.

Les fichiers ne sont pas propres

Ils sortent du système de l'entreprise, pas d'un cours. Il y manque des valeurs, il s'y trouve des lignes en double, des valeurs impossibles, et des colonnes dont l'unité n'est pas celle qu'on croit. Repérer tout ça fait partie du travail.

Corriger, écarter ou signaler : à vous de décider, mais la décision doit être écrite quelque part et tenir en une phrase défendable.

La soutenance

- **15 à 20 minutes** de présentation, puis **10 à 15 minutes** de questions.
- Tous les membres prennent la parole. Les questions peuvent tomber sur n'importe lequel d'entre vous, et sur n'importe quelle ligne du dépôt.
- Des slides avec vos graphiques et vos chiffres. On ne projette pas de code à l'écran.
- Vous parlez à une direction, pas à un professeur : les résultats d'abord, la méthode ensuite, et les recommandations pour finir.

L'IA générative

Elle est à éviter, et pour une raison simple : un code produit par une IA ne survit pas aux questions. Il suffit de demander pourquoi telle ligne est là, ou ce qui se passerait si on changeait tel paramètre. Un groupe incapable d'expliquer son propre code est sanctionné, quel que soit le résultat affiché.

La note

Sur 20 points	
Les neuf questions, méthode justifiée	**13,5**
La synthèse et les décisions proposées	**3,5**
Le dépôt, le README et la soutenance	**3**

Ce qui coûte des points	
Un membre sans aucun commit	**–0,5 par membre**
Tout le code livré en un seul commit	**–1**
Méthode non justifiée	**moitié de la question**
Résultat affiché sans recommandation	**moitié de la question**
Code que le groupe ne sait pas expliquer	**jusqu'à l'annulation de la question**
Fichiers utilisés sans vérification	**points retirés sur les questions touchées**