DATAMINING · PROJET DE FIN DE MODULE

Sujet 6 — Domaine des Trois Rivières

Exploitation viticole, 220 parcelles

Avant de commencer

Cas pédagogique fictif : l'entreprise, les chiffres et les fichiers ont été fabriqués pour cet exercice et ne décrivent aucune société réelle.

Les fichiers sont livrés tels qu'ils sortent du système de l'entreprise. Personne ne les a nettoyés, personne ne vous dira quelles colonnes utiliser, et plusieurs colonnes ne sont pas dans l'unité qu'on attendrait. Chaque réponse doit s'appuyer sur une méthode vue en cours, et le choix de cette méthode doit être justifié : une réponse juste sans justification vaut la moitié des points.

Le contexte

Le Domaine des Trois Rivières exploite 220 parcelles réparties sur plusieurs communes. D'une parcelle à l'autre, le rendement varie du simple au triple sans que personne ne sache l'expliquer, et trois parcelles ont donné l'an dernier des résultats que le chef de culture ne comprend pas. Le budget intrants doit être réparti avant la taille de février, et il est limité.

Les fichiers fournis

Fichier	Contenu
TroisRivieres_parcelles.csv	une parcelle par ligne : surface, cépage, âge des vignes, type de sol, altitude, pente, exposition, densité de plantation, pluviométrie, azote apporté, traitements, position de la parcelle, rendement, classement de la récolte — 223 lignes
TroisRivieres_historique.csv	le rendement et le prix au kilo de chaque parcelle sur les six derniers millésimes — 1 338 lignes

Ce que la direction vous demande

Neuf questions, posées telles qu'elles l'ont été en comité. À vous de décider comment y répondre.

1. Le chef de culture jure que tout vient du sol, l'œnologue parle de l'âge des vignes. Qu'est-ce qui explique vraiment les écarts de rendement d'une parcelle à l'autre ?
2. On nous dit qu'une parcelle qui a bien donné une année donnera bien la suivante. Est-ce que l'historique le confirme ?
3. Avant de répartir le budget intrants, on veut savoir ce que chaque parcelle va donner cette année. C'est toute la trésorerie de la récolte.
4. Sur quoi repose cette prévision, et de combien se trompe-t-elle ? Si l'erreur dépasse l'écart entre deux parcelles, elle ne sert à rien pour arbitrer.
5. On veut repérer à l'avance les parcelles qui vont basculer en classement générique, pendant qu'on peut encore agir dessus.
6. Combien de parcelles faudrait-il traiter en priorité pour rattraper la moitié de celles qui décrochent ? L'équipe ne peut pas tout faire.
7. Les parcelles sont conduites de la même façon depuis trente ans. Combien de types de terroir a-t-on en réalité sur le domaine ?
8. Pour chaque type, quelle conduite — densité, apports, traitements ? C'est ce qu'on veut écrire dans le cahier de culture.
9. En regardant la carte du domaine : les parcelles forment-elles des blocs cohérents, et y en a-t-il qui ne ressemblent à aucune autre et qu'il faut aller voir sur le terrain ?

La synthèse

La répartition du budget intrants : quelles parcelles, quelle dose, quel gain de rendement attendu.

Elle se présente sans une ligne de code : des chiffres, des graphiques, et des phrases qu'un directeur commercial peut lire et décider dessus.